



Primena neuronskih mreža za detekciju finansijskih prevara

Credit Card **Fraud Detection**

Iva Perić 2022/0543 ·
Anja Perović 2022/0391

Struktura prezentacije

01

Opis problema

Disbalans klasa i poslovni cilj

02

Podaci & Preprocesiranje

Dataset, StandardScaler, SMOTE

03

Arhitektura modela

5 konfiguracija: Sklearn, PyTorch, XGBoost, Autoenkoder

04

Trening & Optimizacija

Krive gubitka, hiperparametri, bottleneck

05

Rezultati & Evaluacija

Precision, Recall, F1 — komparativna analiza

06

Zaključak

Izbor optimalnog modela za realnu primenu

Opis problema

0.17%

prevara u skupu

492

od 284.807 transakcija

~100%

Accuracy varljivih modela

Ekstreman disbalans

Regularni modeli ignorišu manjinsku klasu i postižu 99%+ tačnosti proglašavanjem svega legitimnim.

Varljiva metrika

Accuracy je beskorisna. Fokus mora biti na Precision, Recall i F1-Score isključivo za klasu prevara.

Poslovni kompromis

Uhvatiti svaku prevaru ili ne blokirati legitimne korisnike — diametralno suprotni ciljevi u realnom sistemu.

Podaci & Preprocesiranje

284.807

transakcija

492

prevara

30

atributa

80/20

train/test

Atribut	Tip	Opis
V1 – V28	Float (PCA)	Anonimizovane karakteristike transakcije (PCA transformacija)
Time	Float	Sekunde od prve transakcije
Amount	Float	Iznos transakcije u eurima
Class	0 / 1	0 = legitimna transakcija, 1 = prevara

Stratifikacija train_test_split 80/20 sa stratify=y**Data Leakage** Scaler fitovan isključivo na trening skupu**StandardScaler** Samo Time i Amount — V1–V28 već skalirani PCA-om**SMOTE (M3, M4)** 227.451 sintetičkih uzoraka — balans 50:50

Pet eksperimentalnih konfiguracija

M1

Sklearn Baseline

30 → 64 → 16 → 1

Brz baseline, automatski early stopping, arhitektura levka

M2

PyTorch Base MLP

30 → 64 → 16 → 1

BCEWithLogitsLoss, Adam, 20 epoha, potpuna kontrola treninga

M3

XGBoost + SMOTE

100 stabala

Ansamblovsko učenje, greške ispravlja iterativno, max_depth=6

M4

PyTorch + SMOTE

30 → 64 → 16 → 1

Ista MLP arhitektura, trening na balansiranim SMOTE podacima

M5

Autoenkoder

30→16→6→3→6→16→30

Nenadgledano — uči normalno, otkriva anomalije rekonstrukcijom

Trening & Hiperparametarska optimizacija

PyTorch trening petlja (M2, M4)

Loss funkcija:	BCEWithLogitsLoss
Optimizer:	Adam (lr = 0.001)
Batch size:	2048 uzoraka
Epohe:	20
Seed:	42 (reproduktivnost)

Autoenkoder (M5)

Epohe:	50 (+ best state čuvanje)
Loss:	MSELoss (greška rekonstrukcije)
L2 regularizacija:	weight_decay = 1e-4
LR scheduler:	ReduceLROnPlateau (patience=3)
Bottleneck:	3 dimenzije (optimizovano)

Hiperparametarska optimizacija — Bottleneck autoenkodera

Bottleneck	MSE Greška	Napomena
2	0.606773	
3 ✓	0.580401	← optimalan
5	0.496129	
8	0.460548	niža greška, ali loša detekcija

Komparativna analiza performansi

Sve metrike odnose se na klasu prevara (Class = 1) na originalnom test skupu

Model	Precision	Recall	F1-Score	FP (lažne uzbune)
M1 — Sklearn Baseline ★	0.85	0.81	0.83 ★	14
M2 — PyTorch Base MLP	0.81	0.71	0.76	16
M3 — XGBoost + SMOTE	0.35	0.87 ↑	0.49	161
M4 — PyTorch + SMOTE	0.68	0.83	0.75	38
M5 — Autoenkoder	0.15	0.86	0.25	486

Pobednik F1

M1 (0.83)

Najbolji balans Precision/Recall

Max Recall

M3 (0.87)

Hvata najviše prevara, ali 161 FP


Nenadgledano

M5 (0.86 R)

Detektuje bez labeled podataka

Analiza osetljivosti — Model 2

Metoda gradijenta: meri uticaj svake ulazne promenljive na odluku mreže



V14 — ubedljivo najvažniji atribut za detekciju (PCA komponenta sa jakim korelacijama sa originalnim obeležjima)

Zašto Amount na 2. mestu?

Prevaranti tipično:

- Testiraju karticama malim iznosima
- Pokušavaju ekstremno visoke isplate
- Pokazuju neobičan obrazac transakcija

Amount je jedini direktno interpretabilan atribut.

Autoenkoder: 41× veća greška za prevare

Fraud Error = 18.79

Legit Error = 0.45

Model je bez labeled podataka razvio ekstremnu osetljivost na anomalije.

Diskusija

M1 — Apsolutni pobednik (F1 = 0.83)

Sklearn MLP postiže optimalan balans na celom projektu. Svega 14 lažnih uzbuna na 56.864 legitimnih transakcija (0.025%). Idealan za produkcijsku upotrebu gde je operativni trošak lažnih alarma visok.

M4 — Najbolji PyTorch model (F1 = 0.75)

SMOTE podiže Recall na 83% uz svega 38 lažnih uzbuna. Bolji izbor kada je bezbednost prioritet, a kapacitet tima za obradu alarma adekvatan.

Zamka agresivnog balansiranja

pos_weight i preagresivni SMOTE pomeraju granicu odlučivanja previše ka prevarama. M3 generiše 161 lažnu uzbunu — operativno prihvatljivo samo u automatizovanim sistemima.

Nenadgledani pristup — Naučna vrednost M5

Autoenkoder je jedini model koji nikada nije video prevaru tokom treninga. Nezamenljiv za detekciju novih, evoluiranih oblika napada. Niska preciznost nije slabost — 1% saobraćaja ide na dodatnu autentifikaciju.

Zaključak

1

Accuracy je varljiva metrika

Svi modeli postižu ~100% Accuracy. Jedine relevantne metrike su Precision, Recall i F1 za klasu prevara.

2

Sofisticiranije ≠ bolje

Sklearn Baseline postiže najviši F1 (0.83) uprkos svojoj jednostavnosti. Balans arhitekture > složenost.

3

Kontekst određuje model

Izbor zavisi od poslovnog cilja: max balans → M1; max Recall → M3; novi napadi → M5 Autoenkoder.

Preporučeni model prema poslovnom cilju:

Poslovni prioritet	Preporučeni model
Maksimalan F1 balans	M1 — Sklearn MLP
Visok Recall, kontrolisani alarmi	M4 — PyTorch + SMOTE
Apsolutna bezbednost (max Recall)	M3 — XGBoost + SMOTE
Detekcija nepoznatih prevara	M5 — Autoenkoder

Hvala na pažnji!

Duboko učenje i neuronske mreže

Dataset

ULB Credit Card Fraud Detection — Kaggle

GitHub

github.com/anjaperovic/credit-card-fraud

